LIVRET D'APPRENTISSAGE

[Laurent CHOURAKI]

Promotion Gladys West Avril 2026

Certification RNCP38616

➡ Bloc 03 : Appliquer des techniques d'analyse IA via des algorithmes d'apprentissage automatiques.

➡ Bloc 05 : Développer et mettre en production des algorithmes d'IA par apprentissage profond.

Avant de commencer ….

Bienvenue,

Voici le *template* pour l'élaboration de votre Livret d'apprentissage.

Ne changez pas sa mise en forme, afin que les examinateurs concentrent leur attention sur vos réponses.

Respectez la taille du texte, et l'espace disponible.

Savoir être précis et concis est la clé !

Daniel Villa Monteiro

CAS PRATIQUE

Epreuve 1

📅 Semaine 5

Modalités d'évaluation :

Sur la base d'un cas d'entreprise réel ou fictif, le/la candidat(e) doit identifier les enjeux/problématiques rencontrées par l'entreprise. Il/elle doit traduire les enjeux du client en objectifs réalisables. A partir de ces objectifs, il/elle doit programmer, entraîner et utiliser un modèle d'apprentissage profond.

💡 **Cette première épreuve du Livret d'apprentissage permet d'évaluer les compétences suivantes :**

➡ Bloc 3 : Appliquer des techniques d'analyse IA via des algorithmes d'apprentissage automatique

🎓 C1 : **Sélectionner l'algorithme d'apprentissage le plus adapté** en comparant les performances et les caractéristiques des différentes familles d'algorithmes afin d'apporter une réponse pertinente à la problématique métier rencontrée.

🎓 C2 : **Préparer et transformer des données** en utilisant des techniques de prétraitement (preprocessing) pour les adapter aux spécificités du modèle d'apprentissage automatique choisi.

🎓 C3 : **Entraîner un modèle d'apprentissage automatique** en optimisant une loss function (fonction de coût) à partir des données d'entraînement afin de permettre à l'algorithme d'effectuer le moins d'erreurs possibles selon des indicateurs de succès clairement définis.

Epreuve 1 - 1ère Partie

Analyse du besoin :

Le point d'entrée est un dataset comprenant les caractéristiques des pokemons.
Le but est de définir des modèles de classification capables d'effectuer les predictions suivantes:
- D'une part définir si un Pokemon est légendaire en fonction de ses caractéristiques fournies
- D'autre part définir le type d'un Pokemon en fonction de ses caractéristiques fournies

Github : https://github.com/OrenChouraki06/projet-legendary-pokemon

Etat de l'art :

Mon souhait d'explorer plusieurs modèles de machine learning de classification, soit binaire dans le premier cas, soit multi-classe dans le second cas afin de mettre en pratique les connaissances acquises lors de ma formation.

Choix technique :

Dans le premier modele de classification binaire, mon but est d'explorer plusieurs modèles de machines learning pour comparer la valeur d'accuracy, a savoir
- Regression Logistique
- Random Forest
- Gradient Boosting
- Dans la seconde exploration de classification multi-classes, seuls les modèles de Random Forest et de Gradient Boosting seront mis en oeuvre.

Epreuve 1 - 2ème Partie

Mise en oeuvre technique :

Premiere étape : modification du jeu de données
———————-
Dans les deux cas, il nous a fallu faire une exploration du dataset et de le transformer afin d'obtenir des données structurées utilisable pour l'entrainement des modèles.
Ainsi, nous avons constaté qu'une colonne supposée representer des valeurs numériques contenaient une valeur invalide (string).
En outre, une colonne en particulier contenait plusieurs caractéristiques de chaque specimen représentées sous la forme d'une string unique (exemple: « ['caractéristique1', 'caractéristique2', … , 'caractéristique(n)'] »). Il nous a fallu donc transformer cette colonne et la remplacer par plusieurs colonnes correspondantes, simulant ainsi un one hot encoding.
Une fois le dataset modifié, l'étape suivante a consisté a séparer le dataset en 2 jeux de données distincts, une pour l'entrainement et un pour le test.

Deuxième étape: création des pipelines
———————-
L'étape suivante a consisté tout d'abord a définir un pipeline de preprocessing effectuant la transformation des colonnes du dataset pour l'entrainement: one hot encoding pour les colonnes catégorielles (string), puis imputation/scaling pour les colonnes numériques. Nous avons défini deux strategies d'imputation différentes : soit l'imputation d'une valeur neutre particulière, soit l'imputation de la valeur moyenne de la colonne.
Ensuite, la création du modele spécifique a lieu puis la definition d'un pipeline définissant les étapes successives de preprocessing puis d'entrainement et/ou de prédiction.

Troisième étape : entrainement, prediction et evaluation
———————-
L'étape suivante est simple et consiste a entrainer le modele avec le jeu de données d'entrainement, a savoir features et labels.
Enfin, la prediction est effectuée en utilisant le jeu de données de test, mais uniquement les features.
Finalement, l'évaluation du modele est effectuée en comparant la prediction obtenue sur les features du jeu de données de test par rapport aux labels du jeu de données de test. L'accuracy, la loss, et la matrice de confusion ont été obtenues en utilisant les primitives de la bibliothèque scikit-learn.

Quatrième étape : exploration de certains hyper-paramètres avec GridSearch
———————-
La dernière étape a consiste a explorer certains hyper-paramètres des modèles en utilisant le concept de GridSearch, permettant de faire varier ces hyper-paramètres et d'obtenir la meilleure combinaison de valeurs par rapport a celles proposées.

Epreuve 1 - 3ème Partie

Bilan :

Bien sur, cette exploration est essentiellement pédagogique mais elle nous a permis de manipuler les concepts qui ont été enseignés lors de la formation pour le machine learning.

Les valeurs tres élevées d'accuracy obtenues pour la classification binaire, nous ont amené a suspecter que les données contiennent des auto-correlations fortes entre certaines features. En effet, meme après avoir retire du dataset certaines colonnes qui semblaient corrélées au label 'is_legendary' (par exemple 'base_total' ou 'base_egg_steps'), le résultat d'acurracy restait supérieur a 98%.
De meme, le faible ratio légendaire vs. non legendaire nous a amené a réduire le dataset initial afin d'observer si une évolution potentielle de l'accuracy était visible. Ce ne fut néanmoins pas le cas.

Au vu de cette observation, nous avons donc souhaite explorer une seconde classification multi-classes des pokemons en utilisant leurs types. L'accuracy reste assez élevée (plus de 90%) et néanmoins similaire entre les deux modèles sélectionnés, RandomForest ou GradientBoosting. Ici, l'utilisation du GridSearch nous a permis de trouver une combinaison d'hyper-parametres qui n'apportait pas nécessairement une meilleure accuracy mais une meilleure taille du modele (en Mo).

Amélioration :

Dans la premiere classification, il aurait été interessant d'effectuer une clusterisation avec apprentissage non supervisé puis de regarder par exemple le ratio de specimen légendaire vs. non légendaire dans chaque cluster. Ceci afin d'essayer de determiner si certaines features étaient intrinsèquement auto-corrélées.

Dans la seconde classification, une amelioration possible de l'accuracy aurait pu éventuellement consister a explorer une plus grande variété des hyper-paramètres dans le GridSearch.

PROJET FINAL

Epreuve 2

📅 Semaine 13

Modalités d'évaluation :

A partir d'un cas d'entreprise réelle ou fictive, le/la candidat(e) doit développer une application exploitable par un client final intégrant des solutions IA.

💡 **Cette seconde épreuve du Livret d'apprentissage permet d'évaluer les compétences suivantes :**

➡ Bloc 5 : Développer et mettre en production des algorithmes d'IA par apprentissage profond (Deep Learning)

- 🎓 C1 : **Préparer des données non structurées** en les convertissant en données numériques et sous forme tabulaires pour servir de données d'entraînement à un algorithme d'apprentissage profond.
- 🎓 C2 : **Sélectionner l'algorithme d'apprentissage profond le plus adapté** en comparant les performances et les caractéristiques des différentes familles d'algorithmes afin d'apporter une réponse pertinente adaptée à la problématique métier rencontrée.
- 🎓 C3 : **Entraîner un modèle d'apprentissage profond** en optimisant une loss function (fonction de coût) à partir des données d'entraînement afin de permettre à l'algorithme d'effectuer le moins d'erreurs possibles selon des indicateurs de succès clairement définis.

🎓 C4 : **Déployer efficacement un modèle d'apprentissage profond** en utilisant des outils et plateformes de production adaptés (MLOps), pour assurer une accessibilité et une performance optimale des prédictions de l'algorithme aux utilisateurs finaux.

ALYRA

Epreuve 2 - 1ère Partie

Compréhension du besoin client

Décrivez les besoins de votre client fictif, auquel votre projet tente de répondre :

Détecteur de fautes / Validateur d'empreintes digitales

Le but est de mettre a disposition du client fictif un programme permettant de prédire si une photo d'empreinte digitale est lisible, ou plus exactement exploitable, par exemple pour la constitution d'un dossier administratif auprès d'un organisme étatique.
Le client fictif fournirait donc une image représentant une empreinte digitale d'un doigt en noir et blanc et obtiendrait en retour une réponse indiquant si l'image est exploitable.

Github : https://github.com/OrenChouraki06/projet-fingerprint-validator

Epreuve 2 - 1ère Partie

Etat de l'art

Décrivez l'état de la concurrence et des recherches scientifiques quant à votre sujet d'application :

Bien qu'il s'agisse ici uniquement d'un projet pédagogique, l'apprenant a fait face a ce besoin ayant du fournir ses empreintes digitales afin d'établir un extrait de casier judiciaire aux U.S.A. (FBI background check).

La reconnaissance d'empreintes digitales est aujourd'hui disponible dans la poche de tout un chacun disposant d'un smart phone récent. Aussi, il ne s'agit pas ici ni de procéder a une recherche technologique approfondie sur le sujet, ni de mettre en oeuvre une démarche concurrentielle novatrice afin de proposer un produit innovant mais de simplement mettre en pratique les concepts étudiés et assimilés lors de la formation suivie de développement IA de deep learning.

Epreuve 2 - 1ère Partie

Traduction et choix technique du projet

Expliquer l'ensemble de la stack technique que vous utilisez dans votre projet :

La démarche consiste tout d'abord a mettre en oeuvre un réseau de neurones convolutif (modele CNN) afin de prédire l'identification des doigts a partir d'une image d'empreinte digitale fournie.
Ensuite, de relever le niveau de confidence minimum a une valeur significative afin d'établir ou non la lisibilité l'empreinte digitale, en utilisant la confidence de la prediction fournie par le modele CNN mis en oeuvre.

Les techniques d'apprentissage supervisé retenues seront du transfer learning, suivie de fine tuning. Dans ce cadre défini, un réseau CNN pré-entraîné sera sélectionné a partir de la bibliothèque Keras comme modele de base pour la construction du modele CNN complet.

Pour la mise en production, la technologie FastAPI sera mise en oeuvre afin d'accéder au model CNN et a sa fonction de prediction. Enfin, un front-end basique Web sera développé a partir de la technologie Streamlit, afin de permettre d'uploader des images d'empreintes digitales et d'obtenir le résultat de prediction du modele et la réponse sur la lisibilité de l'image.

Bien sur, la recherche d'un dataset d'empreintes digitales constitue en premier lieu la partie critique du projet, afin d'obtenir des résultats pertinents d'entrainement du modele CNN complet.

Epreuve 2 - 2ème Partie

Mise en oeuvre du projet

Expliquez les principales étapes de la mise en oeuvre de votre projet :

Premiere étape: creation d'un dataset d'empreinte digitale
————————————————————————————————

L'objectif principal a été de trouver un dataset contenant un nombre importante d'image d'empreintes digitales. Ma recherche s'est rapidement orientée vers un jeu de données disponible sur Kaggle « SOCOFing ». Ce jeu de données contient:

- 6k images d'empreintes originales, avec une distribution par classes uniforme
- 49k images d'empreintes correspondantes aux images originales 'altérées', c'est-a-dire augmentées (au sens augmentation de données). Suivant 3 niveaux d'altération : faible au moyenne a haute alteration. 3 types d'alteration sont considérées : cut ('coupure' de l'image), blur ('trouble' de l'mage), drop ('goutte' posée sur l'image).

Afin de conserver un ratio raisonnable entre training dataset et validation/test dataset tout en gardant l'entièreté des images originales, les choix suivants ont été faits sur les images du dataset:

- Pour chaque classe
  - Séparer de facon aléatoire les 1.2k images originales en 2 datasets : 800 images pour le training dataset et 400 pour le validation/test dataset
  - Pour chaque image originale sélectionnée aléatoirement dans le training datatset, sélectionner les images correspondantes 'cut', 'blur' et 'drop' faiblement altérées afin de simuler une augmentation de données.
  - Séparer le second validation/test dataset en 200 images pour la validation et 200 pour le test.

En conclusion, le dataset pour l'apprentissage contient 16k pour le training, 1k pour la validation et 1k pour le test. Chaque dataset a une distribution uniforme des classes.

Seconde étape : selection d'un modele pré-entraîné
————————————————————————————-

Au vu de la taille modérée des images du dataset - 96*103 pixels, mon choix s'est rapidement orienté sur la famille de modèles MobileNet. Ceci en suivant l'esprit de « faire plus avec moins », c'est-a-dire choisir d'abord un modele simple, puis uniquement ensuite le complexifier enfin d'obtenir une meilleure performance de prédiction.

Différentes versions de la famille MobileNet ont été explorées lors de la phase du transfer learning, le meilleur compromis restant MobileNetV2, pour un ratio taille du modele (Mo) vs. nombre de paramètres du modele satisfaisant.

Différentes familles de modèles ont également été envisagées, notamment ResNet et EfficientNet. Cependant, le ratio taille du modele vs. nombre de paramètres était nettement en leur défaveur pour un gain - voir une perte, limité en terme d'accuracy.

Troisième étape : transfer learning
—————————————————-
La phase du transfer learning nous a permis d'explorer différentes familles de modele, ResNet et EfficientNet comme nous l'avons indique précédemment. En outre, cette étape a été la plus longue a mettre en oeuvre afin d'obtenir des performances en terme d'accuracy raisonnables.
L'apprentissage a été mené suivant plusieurs axes : tout d'abord, l'entrainement a été effectué avec le dataset basique ne comprenant que les images originales non altérées. Au vue des valeurs d'accuracy obtenues, le second axe s'est développé autour de la classification, c'est-a-dire l'addition progressive du nombre de labels a classifier (deux, puis trois, quatre jusqu'a cinq). Et finalement l'utilisation du dataset augmente a été pris en compte.
Le dernier axe d'amelioration a consiste a explorer l'architecture meme du modele, a savoir l'utilisation d'une, deux ou trois couches denses cachées. Le compromis le plus pertinent par rapport au gain d'amelioration d'accuracy et du nombre de paramètres fut de deux couches cachées, avec une décroissance géométrique de division par 4 : 1280 (sortie du base modele) + 256 (couche cachée 1) + 64 (couche cachée 2) + 5 (classification).
Cependant, l'amélioration la plus conséquente en terme d'accuracy - a savoir environ 3%, fut obtenue grace a l'exploration des fonctions d'activation des couches cachées : leaky_relu, gelu, gelu_approx (avec fonction sigmoid). Encore une fois, le choix retenu fut leaky_rely (slope = 0.01), gelu ou gelu_approx ne montrant pas d'amelioration notable par rapport a leaky_relu, pour un cout d'execution plus important.
Cette dernière étape nous a permis de comprendre le problème du gradient vanishing, qui fut donc légèrement évité avec une fonction d'activation différente.
Un dernier point relatif aux hyper-paramètres : les valeurs de dropout pour les couches associées aux couches denses cachées a été positionné a 30%. Une exploration nous a permis de constater qu'une valeur de 20% apportait une amelioration d'accuracy modérée; la decision fut cependant de garder la valeur initiale afin d'éviter un phénomène d'overfitting.

Quatrième étape : fine tuning
—————————————————-
Comme il a été indique précédemment, la phase de transfer learning fut la plus longue; la phase de fine tuning fut quant a elle relativement systématique.
Il nous semble important de mentioner néanmoins l'exploration liée au gel / dégel des couches du modele pré-entraîne MobileNetV2. Tout d'abord, nous avons considéré un ratio de 2/3 vs. 1/3 entre les couches gelées vs. les couches dégelées. L'exploration a consisté a déterminer quelles étaient les couches a dégeler. L'option 1 fut de considerer 1/3 des premieres couches du modele dégelées et 2/3 des dernières couches du modèle dégelées. L'option 2 fut de considérer toutes les dernières couches du modele dégelées (en gardant le ratio 2/3 vs. 1/3 global bien sur). Bien que potentiellement recommandée pour des images médicales qui auraient pu être tres différentes par rapport aux images utilisées pour entrainer MobileNetV2, l'option 1 n'apporta pas de gain substantiel, et l'option 2 fut donc retenue.

Cinquième étape : evaluation du modele
————————————————————-
Cette étape a consiste a comparer les résultats du modele apres les phases de transfer learning et de fine tuning. L'accuracy du modele est finalement tres (trop) modérée avec les 5 classes (67%), mais légèrement plus acceptable avec 4 classes (70%). La matrice de confusion et l'analyse d'accuracy par classe montre clairement un problème avec le doigt majeur ('middle'), par rapport aux autres classes.
Un point positif reste néanmoins la top-2 accuracy, qui reste acceptable meme pour 5 classes (85%).
Enfin des vérifications simples sur l'evaluation de la prediction du modele avec les dataset validation vs. test montrent un écart tres raisonnable d'accuracy (environ 1%), ce qui tent a montrer que le processus d'overfitting a été contrôlé.

Sixième étape : mise en production
————————————————
La dernière étape a consiste a mettre un oeuvre un front-end a base de la technologie FastAPI, pour accéder a la fonction de prédiction du modele.
Le choix qui a été fait sur la réponse a accorder sur la lisibilité de l'empreinte fut de determiner un threshold parametrable de 75% par default - soit supérieur a l'accuracy du modele, correspondant a la valeur de confiance de la prediction.

En dernier lieu, un point fondamental reste a mentioner : aucune mesure particulière n'a été prise en compte pour la sécurisation des données personnelles, c'est-a-dire des images uploadées dans le front-end. Ceci serait évidemment absolument nécessaire pour une mise en production industrielle. En effet, quoi de plus personnel que des empreintes digitales ?

Epreuve 2 - 3ème Partie

Bilan du projet

Quel bilan tirez-vous de votre projet ? :

Le bilan que je tire de ce projet est positif.

Mon premier objectif étant de mettre en application l'apprentissage dispensé lors de la formation sur le deep learning, j'ai pu au travers d'une application simple et ce dans le cas strict d'un projet pédagogique, mettre en oeuvre les concepts de réseaux de neurones convolutifs, d'apprentissage supervisé avec transfer learning et fine tuning en utilisant un modele existant de computer vision pré-entrainé, et finalement de techniques de mise en production.

Le fait d'avoir obtenu une performance tres moyenne du modele entrainé, m'a montré par la preuve l'importance du travail de recherche et de manipulation du dataset a fournir pour entrainer un tel modele;, ainsi que son aspect critique pour obtenir des performances satisfaisantes.

La phase d'apprentissage du modele ma permis d'explorer different modèles pré-entraînés, différentes architectures de couches denses ainsi que de leurs fonctions d'activation et paramètres associés (relu, leaky_relu, gelu, gelu_approx), et enfin des hyper-paramètres relatif au processus d'apprentissage lui-même (epochs, patiences, ratios des layers frozen vs. unfrozen).

En conclusion, cet exercise pédagogique m'a permis de vérifier la maxime « faire plus avec moins » au sujet du deep learning, ayant par mon expérience entendu plus souvent par le passé « qui peut le plus peut le moins ».

Epreuve 2 - 3ème Partie

Axes d'améliorations

Si vous aviez 1 mois pour finaliser votre projet, quelles sont les fonctionnalités que vous ajouteriez ? :

Avec une période supplémentaire de développement, plusieurs axes d'amelioration auraient pu être envisages:

Tout d'abord, au vue des résultats d'accuracy décevants sur 5 classes, une recherche plus approfondie de 'features' d'empreintes digitales aurait été menée, afin d'identifier de nouveaux labels potentiels pour determiner si une empreinte est utilisable ou non. Et non pas l'identification elle-même des doigts.

En outre, une autre approche d'apprentissage supervisé aurait été explorée, consistant a mettre en oeuvre la technique de distillation, afin d'essayer d'obtenir de meilleures valeurs d'accuracy. Par exemple, en considérant comme modele 'Teacher' un modele de computer vision type MobileNet - voire plus élaboré type ResNet ou EfficientNet, et considérant comme modele une version simplifiée de MobileNet avec moins de blocks résiduels de convolution.
Enfin nous aurions pu explorer l'emploi direct de modèles pré-entraînes; cela n'aurait certes pas répondu aux besoins pédagogiques de cette formation, mais aurait pu fourni un point de données supplémentaire sur l'accuracy.

Enfin, un module de sécurisation des données personnelles des utilisateurs serait développé.

Epreuve 2 - Conclusion

Retour sur vos 3 mois de formation, votre apprentissage, vos motivations et vos éventuels regrets :

Le bilan que je tire de cette formation est extrêmement positif.

Sur ces deux projets pédagogiques, j'ai la forte conviction d'avoir fait l'experience de deux extremes en IA:
Tout d'abord sur le machine learning, disposant d'une pléthore de données, la mise en oeuvre d'un modele s'éloigne significativement de la philosophie de 'prédiction'.
Sur l'aspect du deep learning, utiliser un modele de réseau de neurones convolution est difficile pour généraliser une prediction pour des données tres spécifiques telles que les empreintes digitales. Et tout particulièrement pour des données tres similaires par rapport aux classes différentes a identifier.

De formation d'ingenieur informatique, et ayant assumé des roles de management ces 25 dernières années, il m'apparaissait absolument nécessaire de comprendre les enjeux technologiques et théoriques associes au machine learning ou deep learning. Et donc de préférer une formation de développement IA et non de consulting IA.

Ma motivation principale est en effet de ne pas prétendre devenir un expert en développement IA mais de pouvoir me positionner comme chef de projet informatique IA. Mon experience de chef de projet et directeur informatique dans le high-tech m'a conforté dans ma conviction que pour assumer un tel role, un leader se doit de comprendre et maitriser les technologies mise en oeuvre par ses équipes, afin d'en comprendre les limites et enjeux intrinseques.

Un simple regret tient dans le fait que la formation n'adresse pas la technologie d'apprentissage par réenforcement.